Identificazione dei giocatori da video broadcast

Stato dei lavori: quattro fronti e un risultato architetturale

Lorenzo Cappetti

Luglio 2026

Di cosa parliamo

I quattro fronti

1. Detector della regione del numero
2. Recognizer del numero (CTC)
3. Assegnazione identità via roster
4. Collo di bottiglia nel tracking

Novità

- La *decisione* come parametro misurabile
- Il limite di dominio, quantificato

Filo conduttore

Ogni risultato è accompagnato da:

- su quali dati è misurato;
- se quei dati erano mai stati usati prima;
- transizioni, non solo medie;
- intervallo di confidenza.

Diversi risultati sono **negativi**: sono riportati perché delimitano ciò che i risultati positivi significano.

Come misuro (vale per tutte le slide successive)

Separazione dei dati

- Split **per sequenza**, mai per crop: frame quasi identici della stessa partita non possono finire in train e test.
- Blocchi dichiarati *prima* di guardare i numeri.
- Il test GSR è stato usato **una volta sola**, a configurazione congelata.

Confronto

- Stessa superficie: stessi frame, stesse track, stessi crop.
- Una sola variabile per ablation.
- Transizioni *paired*: non basta la media, serve sapere quanti casi corretti sono diventati errati.
- Bootstrap che campiona **sequenze intere**, non tracklet.

Perché la media non basta

Due metodi possono avere la stessa accuratezza finale e comportarsi in modo opposto:

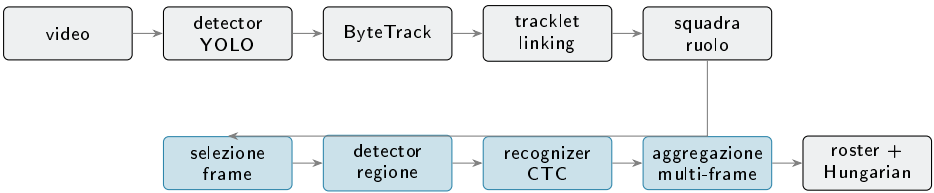
- uno aggiunge risposte dove prima c'era silenzio;
- l'altro cambia risposte già corrette.

Solo la matrice delle transizioni li distingue.

Perché bootstrap per sequenza

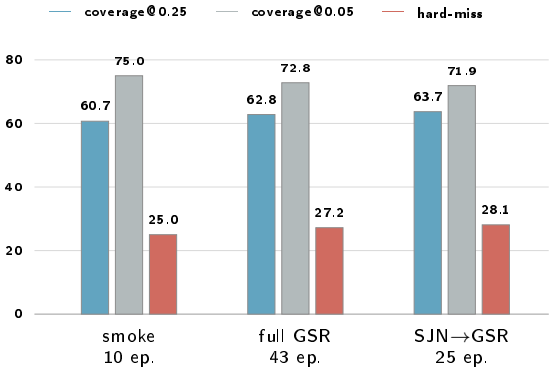
I tracklet della stessa partita non sono indipendenti: stessa maglia, stessa luce, stessa telecamera. Campionare tracklet gonfierebbe la significatività.

La pipeline



In azzurro la catena del numero di maglia, dove si concentra il lavoro. Ogni stadio può fallire indipendentemente: un recognizer perfetto è inutile se il detector non gli passa la regione, e un numero corretto è inutile se la tracklet mescola due giocatori.

Fronte 1 — Detector della regione: più training non aiuta

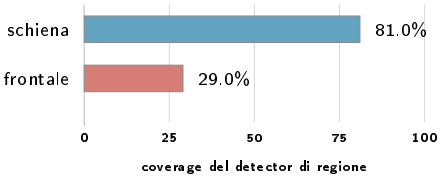


Tre varianti, **stesso** dataset (435 immagini, 37 sequenze), stesso seed.

- La coverage alla soglia operativa sale di 3 punti.
- La coverage a soglia bassa **scende**.
- Gli *hard-miss* **aumentano**.

Il detector diventa più *sicuro* quando rileva, non più *capace* sui casi ambigui. **Nessuno dei tre promosso.** **Come**: coverage misurata sul blocco frozen di 11 sequenze, mai usato per training o scelta del checkpoint.

Fronte 1 — Perché non è la selezione del frame



Orientamento stimato con un pose estimator generico, **zero training**. Keypoint affidabili su 763/865 crop.

Scomposizione dei fallimenti gravi:

spiegati da "non è schiena"	78.2%
crop è schiena, fallisce comunque	21.8%

Il pose è un ottimo **diagnostico**. Ma la ri-selezione dei frame basata su di esso è stata provata e **non ha funzionato**, come due classificatori dedicati:

	AP	effetto sull'OCR
clean-back YOLO	0.932	nullo o negativo
readability YOLO	0.999	nullo o negativo

Quel 21.8% è il motivo: in quei casi il frame giusto era già stato scelto, e il detector sbaglia comunque.

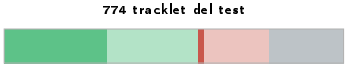
Fronte 2 — Recognizer: il transfer da un dataset esterno

Architettura: **CRNN + CTC** (ResNet18 + BiLSTM), legge il numero come sequenza di cifre invece che come una classe fra 100.

Il confronto è fra **due checkpoint CTC**: cambia solo il pretraining. Misura il valore di **SJN-210k**, non dell'architettura.

Test GSR, 774 tracklet	solo GSR	SJN→GSR
coverage regione	61.0%	61.0%
coverage tracklet	78.2%	78.2%
corretti	249	**442**
errati	356	**163**
accuracy assegnata	41.2%	**73.1%**
accuracy complessiva	32.2%	**57.1%**
GT nel top-5	386	**521**

Come: stessa superficie: stessi 2954 crop, stesse 1803 regioni. Una sola valutazione, configurazione congelata prima.



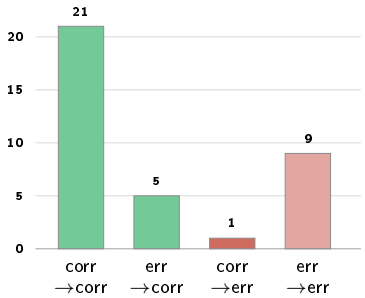
Guadagno netto +193 tracklet.
Bootstrap: $\Delta = +0.249$,
IC 95% [+0.222, +0.278].

Fronte 3 — Roster: vincolare le predizioni alla rosa reale

Il numero letto dall'OCR è una *proposta*. La rosa dice quali numeri sono possibili: un numero fuori rosa è certamente sbagliato.

Int-Ata, 36 track valutate	accuracy assegnata
senza roster	61.1% (22/36)
con roster	**72.2%** (26/36)

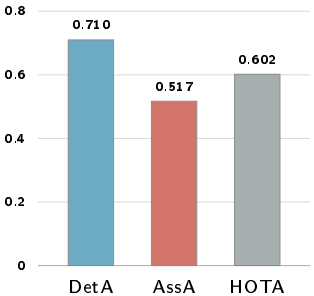
Come: ground truth etichettata a mano (Identity Benchmark V1), disambiguata per segmento di scena; nessun tracklet escluso come ambiguo.



5 recuperi contro 1 regressione, guadagno netto $+4$.

La regressione è reale ed è riportata: è comparsa dopo la disambiguazione per scena, che ha reso visibili casi prima esclusi.

Fronte 4 — Dove si perde il tracking



$$\mathrm{HOTA} \approx \sqrt{\mathrm{DetA} \times \mathrm{AssA}}$$

19 punti separano il trovare le persone dal mantenerne l'identità nel tempo.

recall detection	95.8%
AP @ IoU 0.50	0.951
AP @ IoU 0.75	0.619
cambi di identità	1298
frammentazioni	1941

Il detector *trova* quasi tutti ma *localizza* male: il crollo da AP50 a AP75 dice che i box sono imprecisi. Box imprecisi rendono difficile l'associazione, che si basa sulla sovrapposizione fra frame consecutivi.

Come: 12 sequenze, 9000 frame, metriche TrackEval-compatibili.

Idea: conoscendo le posizioni in metri sul campo si possono scartare associazioni fisicamente impossibili.

errore di posizione	mediana	P90
calibrazione automatica	35.78 m	58.28 m
TVCalib	**1.10 m**	**2.71 m**

La geometria funziona benissimo. Usata nel sistema, però:

	ΔHOTA	seq. migliorate
vincolo rigido	−0.00076	1 su 12
costo morbido	−0.00019	0 su 12

Perché non funziona

Esportando i candidati reali del linker: in **22 casi su 50** il candidato corretto *non è presente* nella lista.

Il linker non sbaglia a scegliere: gli manca l'opzione giusta fra cui scegliere. Nessun riordino può recuperare ciò che non è candidato.

Scartare TVCalib non è "non ha funzionato": è aver localizzato il problema un passo più a monte, nella **generazione** dei candidati invece che nel loro ordinamento. **Come**: ablation end-to-end sullo stesso pilot di 12 sequenze, una sola variabile per volta.

Fronte 4 — Splitter: tracklet che mescolano due giocatori

Il tracker a volte assegna **un solo ID a due persone** (incroci, occlusioni, cambi di inquadratura). Una tracklet contaminata avvelena tutto ciò che sta a valle: il numero viene aggregato su due giocatori.

DBSCAN sugli embedding d'aspetto *dentro* la tracklet, ispirato a GTA (Sun et al.).

video	track	flag	confermati
Int-Ata	89	5	1 vero pos., 4 incon.
Inter-Juve	39	0	0 attesi
Inter-Atalanta	20	0	0 attesi

Cosa si può e non si può dire

Sì: nessun falso positivo grossolano — sui due video dove il ground truth non conosce mescolamenti, zero segnalazioni.

Sì: il caso reale è stato isolato con uno split quasi esatto sul confine vero, e segnalato indipendentemente anche da una seconda misura di coerenza d'aspetto.

No: con *un* vero positivo non si stima il richiamo.

Non ancora integrato nel sistema: resta audit-only, non applica nessuno split. È il prossimo passo naturale.

Novità — La decisione come parametro

Nel sistema convivono **due lettori** del numero: il SAR (OCR generico) e il CTC di regione. Finora il secondo era in sola osservazione.

Ho reso esplicito *chi decide* quando le due sorgenti dicono cose diverse:

```
sources:  [sar, ctc]  oppure  [ctc, sar]
```

Vince la prima sorgente che **ha deciso**; le successive parlano solo dove le precedenti si astengono. Nessun modello nuovo, nessun training: cambia solo l'ordine di precedenza fra due componenti già presenti.

Perché è una domanda, non un dettaglio

L'ordinamento conservativo ("non scavalcare mai chi ha già deciso") è prudente *solo se* chi decide è affidabile.

Se la sorgente prioritaria sbaglia spesso, proteggerla significa ereditarne gli errori.

Verifica preliminare

Con l'ordine storico, l'output del sistema è rimasto **invariato bit a bit**: il cambiamento è a rischio zero finché non si tocca la configurazione.

Novità — Protocollo: un blocco nuovo, dichiarato prima

Tutti i blocchi GSR erano già stati aperti: 37 sequenze per il training OCR, 9 per lo sviluppo, 11 per il frozen; il test è congelato.

Sono state individuate **7 sequenze mai usate** nello split di validazione, con esclusioni *derivate*: 9900 file scansionati, ogni sequenza scartata registrata con il file che la squalifica.

sequenze	7
tracklet con numero GT	116
manifest	auto-hashato, seed fisso

Due politiche **dichiarate in anticipo**, prima di osservare qualunque risultato congiunto.

Vincolo che pesa sul futuro

Dopo questo blocco, GSR **non ha più superficie pulita**.

Una domanda successiva dovrà spendere il test congelato — una volta sola — oppure appoggiarsi a video senza etichette.

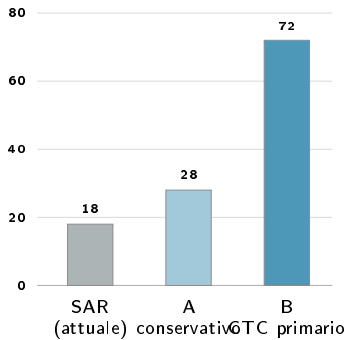
I due bracci

A conservativo: SAR decide, CTC solo dove il SAR tace.

B aggressivo: CTC decide, SAR di ripiego.

A non può, per costruzione, peggiorare un tracklet già corretto.

Novità — Risultato: l'ordine vale più del riconoscitore



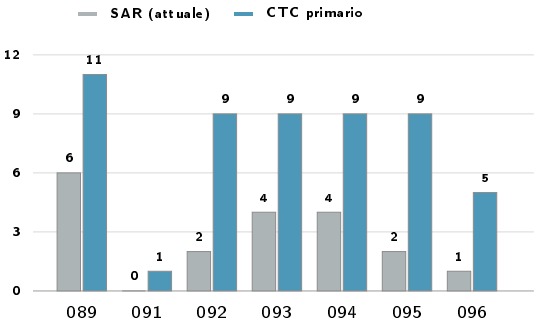
Tracklet corretti su 116.
Superficie offline: box e track dalla ground truth.

I due bracci assegnano **gli stessi 95 tracklet**: la copertura non dipende dall'ordine. Cambia solo *chi* risponde.

A contro B	48 discordanti
vince B	46
vince A	2
Δ accuracy	$+0.378$
IC 95%	$[+0.275,\ +0.496]$
binomiale esatto	$p = 8.4 \times 10^{-12}$

Il braccio conservativo cattura meno di un quinto del guadagno disponibile: lascia intatti 60 tracklet su cui il SAR ha deciso sbagliando, dei quali il CTC ne corregge 46.

Novità — Il risultato sopravvive al tracking reale



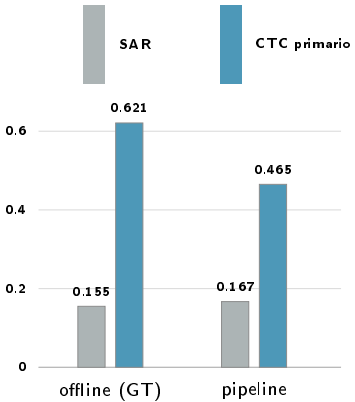
Detection e tracking reali. Il CTC vince in **7 sequenze su 7**.

114 tracklet	SAR	CTC
emessi	63	94
corretti	19	**53**
accuracy	0.167	**0.465**

recuperi	37
regressioni	**3**
Δ accuracy	$+0.298$
IC 95%	$[+0.208,\ +0.374]$
McNemar esatto	$p = 1.9 \times 10^{-8}$

Come: stessa detection e stesso tracking nei due bracci: unica variabile la riga di configurazione.

Novità — Le due superfici a confronto



Accuracy complessiva.

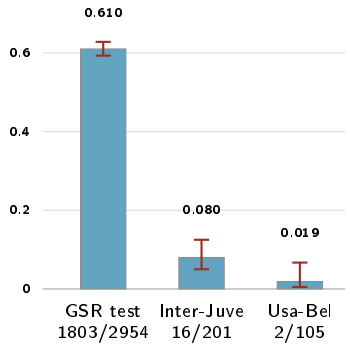
Circa **due terzi** del guadagno sopravvive al rumore di detection e tracking.

	offline	pipeline
errato → corretto	46	17
corretto → errato	2	3

I recuperi calano molto; le regressioni restano stabili.

Lettura: il rumore del tracking non rende il CTC *più sbagliato*, lo rende *più silenzioso* — crop peggiori, meno regioni rilevate, meno occasioni di correggere. Degradazione benigna. Le due superfici hanno unità e denominatori diversi: vanno lette separatamente, non confrontate numero a numero.

Il limite: il detector di regione non esce da GSR



Coverage del detector di regione.
Barre di errore: intervalli di Wilson al 95%.

Il confondente della risoluzione è escluso: Usa-Bel è 1920×1080 come GSR, e i giocatori sono *più grandi* (altezza mediana del crop 102 px).

Non è qualità dell'immagine: è il **dominio visivo** — design delle maglie, grafia dei numeri, illuminazione, angolo di ripresa.

Su Usa-Bel il CTC parla su 2 tracklet su 13: la domanda sull'ordinamento non si pone nemmeno. Il campione dei video custom è piccolo e gli intervalli sono larghi: si può affermare "molto sotto GSR", non ordinare fra loro Inter-Juve e Usa-Bel. **Come:** stesso detector di regione congelato in tutti e tre i casi; unica variabile il video.

Sintesi

Risultato	Dove è misurato	Stato
Pretraining SJN-210k del recognizer	Test GSR, 774 tracklet, una volta sola	Validato: +32 punti
Vincolo del roster sull'identità	Int-Ata, 36 track etichettate a mano	Validato: +11 punti
Ordine di precedenza fra sorgenti	Held-out 7 sequenze, due superfici	Misurato, non promosso
Retraining del detector di regione	Frozen, 11 sequenze	Negativo: nessuno promosso
TVCalib come vincolo fisico	Pilot 12 sequenze, end-to-end	Scartato: problema a monte
Splitter di tracklet contaminate	3 video, 148 tracklet	Audit-only, non integrato

Domande aperte

1. Testare l'ipotesi sulla diversità

Oggi è un'inferenza da un pattern, non un test. Due disegni a parità di quantità:

- curva di apprendimento su sottoinsiemi — siamo limitati da quantità o da varietà?
- stesso N da poche sequenze contro molte sequenze.

Inoltre: 277 crop già verificati da video custom non sono ancora stati usati per il training (+64% sulle 435 originali, da un dominio diverso).

2. Integrare lo Splitter

Misura mirata, non aggregata: sui tracklet divisi il numero diventa corretto? Con un solo vero positivo l'effetto su HOTA sarebbe invisibile.

3. Il criterio di promozione

La regola attuale richiede zero regressioni *e* zero nuove emissioni errate:

braccio A	0 regressioni, 7 nuovi errori
braccio B	3 regressioni, 16 nuovi errori

Boccia entrambi, incluso quello che triplica i tracklet corretti su due superfici indipendenti. Un vincolo di zero nuove emissioni errate rende impossibile qualunque aumento di copertura.

4. Il dominio

Il recognizer legge bene; il problema è che fuori da GSR non gli arriva quasi nulla da leggere. È lì che si decide se il sistema funziona su video reali.